

5 КЛАССИФИКАТОРЫ, ОСНОВАННЫЕ НА НЕПАРАМЕТРИЧЕСКИХ ОЦЕНКАХ ПЛОТНОСТИ ВЕРОЯТНОСТЕЙ

Цель работы – изучение теоретических основ и экспериментальное исследование классификаторов, основанных на непараметрических методах оценивания плотности вероятностей, для распознавания образов.

В лабораторной работе изучаются методы построения классификаторов, основанных на непараметрических методах оценивания плотности вероятностей, в частности: оценки Парзена, метода ближайшего соседа и K -ближайших соседей.

5.1 Теоретические основы лабораторной работы

Если известны плотности вероятностей (далее – ПВ) случайного вектора признаков для каждого класса и априорные вероятности классов (при простейшей матрице штрафов), то оптимальной стратегией классификации является использование байесовского классификатора в виде:

$$\forall j \neq l \quad P(\Omega_l) f\left(\bar{x} / \Omega_l\right) > P(\Omega_j) f\left(\bar{x} / \Omega_j\right) \Rightarrow \bar{x} \in D_l. \quad (5.1)$$

Если соответствующие плотности и вероятности неизвестны, естественный подход состоит в нахождении их оценок $\hat{f}\left(\bar{x} / \Omega_l\right)$, $\hat{P}(\Omega_l)$ на основе имеющейся обучающей выборки объектов из каждого класса и использовании выражения (5.1) с заменой теоретических величин на эмпирические. Ниже представлены краткие сведения, необходимые для построения и использования классификаторов, использующих два метода непараметрического оценивания ПВ: метод Парзена и метод K ближайших соседей.

5.1.1. Метод Парзена оценивания плотности вероятностей

Пусть $\{\bar{x}_i\}_{i=0}^{N-1}$ – N независимых реализаций случайного вектора $\bar{X}$ размерности n , распределенного по закону, задаваемому неизвестной ПВ $f(\bar{x})$. Метод Парзена получения состоятельных оценок ПВ $f(\bar{x})$ состоит в использовании непрерывных функций вида $\frac{1}{h^n} k\left(\frac{\bar{x} - \bar{x}_i}{h}\right)$, соотнося их с каждым выборочным значением $\bar{x}_i$, при определенных требованиях к h и функции k . В соответствии с этой идеей приходим к оценке вида

$$\hat{f}_N(\bar{x}) = \frac{1}{N} \sum_{i=0}^{N-1} \frac{1}{h^n} k\left(\frac{\bar{x} - \bar{x}_i}{h}\right), \quad (5.2)$$

где функция $\frac{1}{h^n} k\left(\frac{\bar{y}}{h}\right)$ называется *ядром оценки*. Оценка (5.2) используется в случае «круговых» (изотропных) ядер. Для «некруговых» ядер можно использовать следующую формулу (когда $h_1 \neq h_2 \neq \dots \neq h_N$):

$$\hat{f}_N(\bar{x}) = \frac{1}{N} \cdot \sum_{i=0}^{N-1} \left(\prod_{j=0}^{n-1} h_j \right)^{-1} \cdot k\left[\frac{x_0 - \bar{x}_0^i}{h_0}, \dots, \frac{x_n - \bar{x}_{n-1}^i}{h_{n-1}} \right]. \quad (5.3)$$

Утверждение. Оценка (5.2) является асимптотически несмещенной и состоятельной оценкой функции ПВ $f(\bar{x})$ в точках ее непрерывности, если функция $k\left(\frac{\bar{y}}{h}\right)$ и число h удовлетворяют следующим условиям:

$$\int_{R^n} k\left(\frac{\bar{y}}{h}\right) d\frac{\bar{y}}{h^n} = \int_{R^n} k(\bar{z}) d\bar{z} = 1, \quad (5.4)$$

$$\int \left| k\left(\frac{\bar{y}}{h}\right) \right| d\frac{\bar{y}}{h^n} = \int |k(\bar{z})| d\bar{z} < \infty, \quad (5.5)$$

$$\sup_{\frac{\bar{y}}{h} \in R^n} \left| k\left(\frac{\bar{y}}{h}\right) \right| = \sup_{\bar{z} \in R^n} |k(\bar{z})| < \infty, \quad (5.6)$$

$$\lim_{\frac{\bar{y}}{h} \rightarrow \infty} \left| \frac{\bar{y}}{h} k\left(\frac{\bar{y}}{h}\right) \right| = \lim_{|\bar{z}| \rightarrow \infty} |\bar{z} k(\bar{z})| = 0, \quad (5.7)$$

$$\lim_{n \rightarrow \infty} h^n(N) = 0 \quad (\text{условие асимптотической несмещенности}) \quad (5.8)$$

$$\lim_{n \rightarrow \infty} N \cdot h^n(N) = \infty \quad (\text{условие состоятельности}) \quad (5.9)$$




Рисунок 5.1 – Иллюстрация к оценке Парзена ПВ

В случае, если дополнительно к условиям (5.4)–(5.9) выполняется следующее условие

$$\lim_{n \rightarrow \infty} N \cdot h^{2n}(N) = \infty \quad (\text{условия равномерной состоятельности}),$$

то при некоторых дополнительных ограничениях оценка (5.2) является *равномерно состоятельной*:

$$\forall \varepsilon > 0 \quad \lim_{N \rightarrow \infty} \cdot P \left\{ \sup_{-\infty < x < \infty} \left| \hat{f}_N(x) - f(x) \right| > \varepsilon \right\} = 0.$$

Примером многомерного ядра, имеющего вид нормальной ПВ. Это ядро определяется следующим образом:

$$\begin{aligned} \frac{1}{h^n} \cdot k \cdot \left(\frac{\bar{x} - \bar{x}_i}{h} \right) = \\ = (2 \cdot \pi)^{-n/2} \cdot h^{-n} \cdot |B|^{-1/2} \cdot \exp \left[-\frac{1}{2} \cdot h^{-2} \cdot (\bar{x} - \bar{x}_i)' \cdot B^{-1} \cdot (\bar{x} - \bar{x}_i) \right]. \end{aligned} \quad (5.10)$$

Здесь, очевидно:

$$(2 \cdot \pi)^{-n/2} \cdot h^{-n} \cdot |B|^{-1/2} = \frac{1}{(2 \cdot \pi)^{n/2} \cdot \sqrt{|B|} \cdot h^n}.$$

Примечание. Пусть в выражении (5.11) в качестве матрицы B использована выборочная ковариационная матрица $\hat{B}$, рассчитанная по выборке. Тогда ковариационная матрица оценки Парзена B_p и матрица $\hat{B}$ связаны соотношением:

$$B_p = \frac{1}{N} \cdot \sum_{i=0}^{N-1} \left(\bar{x}_i \cdot \bar{x}_i' + h^2 \cdot \hat{B} \right) \approx (1 + h^2) \cdot \hat{B}.$$

Параметр $h(N)$ удобно использовать в виде:

$$h(N) = N^{-\frac{k}{n}} = \left(N^{-\frac{k}{n}} \right). \quad (5.11)$$

Для выполнения условий (5.8) – (5.10) величина k должна удовлетворять следующим ограничениям: $1 > k > 0$ – условие состоятельности, $\frac{1}{2} > k > 0$ – условие равномерной состоятельности.

Примеры одномерных ядер, используемых в оценке Парзена, приведены ниже.

Прямоугольное ядро

$$\frac{1}{h}k\left(\frac{y}{h}\right)=\begin{cases} \frac{1}{2h}, & \left|\frac{y}{h}\right|\leq 1, \\ 0, & >1. \end{cases}$$

Треугольное ядро

$$\frac{1}{h}k\left(\frac{y}{h}\right)=\begin{cases} \frac{1}{h}\left(1-\left|\frac{y}{h}\right|\right), & \left|\frac{y}{h}\right|\leq 1, \\ 0, & >1. \end{cases}$$

Нормальное ядро

$$\frac{1}{h}k\left(\frac{y}{h}\right)=\frac{1}{\sqrt{2\pi}h}\exp\left(-\frac{y^2}{2h^2}\right),$$

Экспоненциальное ядро

$$\frac{1}{2h}\exp\left(-\frac{y}{h}\right),$$

Рациональное ядро

$$\frac{1}{\pi h} \frac{1}{1+\left(\frac{y}{h}\right)^2},$$

Ядро "sinc"

$$\frac{1}{\pi h} \left(\frac{\sin \frac{y}{2h}}{\frac{y}{2h}} \right)^2,$$

Достоинства и недостатки оценки Парзена

К достоинствам оценки следует отнести ее универсальность. Недостатками оценки являются ее высокая вычислительная сложность (число слагаемых в выражении (2) соответствует объему обучающей выборки); необходимость хранения всей обучающей выборки; неоднозначность оценки, связанной с произвольностью выбора ядер и величины $h=h(N)$.

5.1.2. Метод K ближайших соседей

Используя выборку $\{\bar{x}_i\}_{i=0}^{N-1}$ объема N , найдем расстояние r от точки $\bar{x}$ до K -го ближайшего к $\bar{x}$ элемента выборки (K -го ближайшего соседа). Для измерения «близости» можно воспользоваться любой подходящей меркой. Тогда в качестве оценки ПВ в точке $\bar{x}$ можно принять:

$$\hat{f}_N(\bar{x}) = \frac{K}{N} \cdot \frac{1}{A(k, N, \bar{x})}, \quad (5.12)$$

где $A(k, N, \bar{x})$ – объем множества всех точек, расстояние которых до $\bar{x}$ меньше, чем r . Величина A является случайной (и зависит фактически от $\bar{x}$), зависящей от выбранного множества N элементов выборки.

Утверждение. Если параметр $K(N)$, удовлетворяет условиям:

$$\lim_{N \rightarrow \infty} K(N) = \infty,$$

$$\lim_{N \rightarrow \infty} \frac{K(N)}{N} = 0,$$

то оценка (5.12) является асимптотически несмещенной и состоятельной оценкой ПВ $f(\bar{x})$ в точках ее непрерывности.

5.1.2.1 Решающее правило K ближайших соседей

Полученная оценка $\hat{f}_N(\bar{x})$ ПВ может использоваться следующим образом. Когда требуется классифицировать неизвестный объект (вектор признаков) $\bar{x}$, среди имеющихся N объектов (уже проклассифицированных), из которых N_l объектов из класса

$\Omega_l \left(\sum_{l=0}^{L-1} N_l = N \right)$, находят K ближайших к точке $\bar{x}$ объектов.

Пусть $k_l \ (l=\overline{0, L-1})$ – число объектов из класса Ω_l среди этих K ближайших соседей $\left(\sum_{l=0}^{L-1} K_l = K \right)$. Тогда оценка ПВ принимает вид

(в l -м классе):

$$\hat{f}_{N_l}^i \left(\bar{x} / \Omega_l \right) = \frac{K_l}{N_l} \cdot \frac{1}{V}, \quad l = \overline{0, L-1}. \quad (5.13)$$

Поскольку независимо от номера класса, K_l объектов извлечены из одной и той же области A , то величина объема V оказывается одинаковой для всех классов. Следовательно, байесовский классификатор (5.1), минимизирующий общий риск, будет иметь вид (оценку априорной вероятности берем в виде (5.15):

$$\hat{P}(\Omega_l) = \frac{N_l}{N}:$$

$$\forall j \neq l \quad \frac{N_l}{N} \cdot \hat{f}_N \left(\bar{x} / \Omega_l \right) \geq \frac{N_j}{N} \cdot \hat{f}_N \left(\bar{x} / \Omega_j \right) \Rightarrow \bar{x} \in D_l.$$

Подставляя в это выражение значение из (13), получим:

$$\forall j \neq l \quad \frac{N_l}{N} \cdot \frac{K_l}{N_l \cdot V} \geq \frac{N_j}{N} \cdot \frac{K_j}{N_j \cdot V} \Rightarrow \bar{x} \in D_l$$

или

$$\forall j \neq l \quad K_l \geq K_j \Rightarrow \bar{x} \in D_l. \quad (5.14)$$

Окончательно, решающее правило можно записать в виде:

$$l = \arg \max_{j=0, L-1} K_l, \quad \bar{x} \in D_l.$$

5.1.2.2 Решающее правило K ближайших соседей для двух классов

Из соотношения (14) непосредственно следует:

$$K_0 > K_1 \Rightarrow \bar{x} \in \begin{cases} D_0 \\ D_1 \end{cases}$$

Таким образом, решение о принадлежности вектора $\bar{x}$ принимается в тот класс, соседей которого больше. Для устранения возможных проблем с «равенством» числа соседей, число K в случае двух классов следует брать нечетным.

5.1.2.3 Решающее правило ближайшего соседа

В случае $K=1$ решающее правило называют *правилом ближайшего соседа*. В соответствие с этим правилом решение о принадлежности вектора $\bar{x}$ принимается в тот класс, у которого оказался ближайший к $\bar{x}$ сосед.

Достоинства и недостатки решающего правила K соседей

Достоинство: решающее правило, основанное на методе K ближайших соседей, является очень простым и не требует знания (явного построения) ПВ (или ее оценки).

Его *недостаток* заключается в необходимости хранить в памяти машины все объемы (всю обучающую выборку) и сравнивать каждый из них с неизвестным объектом.

5.1.3 Оценка априорных вероятностей

Оценка величин $P(\Omega_l)$ для больших объемов обучающей выборки может быть выполнена следующим образом:

$$\hat{P}(\Omega_l) = \frac{N}{N_l}, \quad N = N_0 + \dots + N_{L-1}, \quad (5.15)$$

Здесь N – общее количество элементов обучающей выборки во всех классах; N_l – количество элементов выборки в l -м классе.

5.2 Порядок выполнения лабораторной работы

5.2.1 Исходные данные

- Два файла данных, полученных в процессе выполнения первой лабораторной работы (см. раздел 1 настоящего издания) и содержащих наборы двумерных нормально распределенных векторов признаков для ситуации равных корреляционных матриц; параметры этих законов распределения; параметры байесовского классификатора для ситуации равных корреляционных матриц (см. раздел 2 настоящего издания).
- Два файла данных, полученных в процессе выполнения первой лабораторной работы (см. раздел 1 настоящего издания) и содержащих наборы двумерных нормально распределенных векторов признаков для ситуации неравных корреляционных матриц; параметры этих законов распределения; параметры байесовского классификатора для ситуации неравных корреляционных матриц (см. раздел 2 настоящего издания).
- Исполняемый в Python файл, необходимый для выполнения п.2 из плана выполнения лабораторной работы.

5.2.2 Общий план выполнения работы

1. Синтезировать дополнительные реализации для каждого из классов (использовать результаты и файлы лабораторной работы № 1), соответствующих существующим исходным данным (см. 5.2.1).

2. Построить классификатор, основанный на непараметрической оценки Парзена, используя сгенерированные на предшествующем шаге данные как обучающие выборки, а данные из первой лабораторной работы – как тестовые. В качестве ядра взять гауссовское (5.10), величину h взять в виде (5.11). Оценить эмпирический риск – оценку суммарной вероятности ошибочной классификации.

3. Построить классификатор, основанный на методе К ближайших соседей (для $K=1,3,5$), используя сгенерированные в п.1 данные как обучающие выборки, а данные из первой лабораторной работы – как тестовые. Оценить эмпирический риск – оценку суммарной вероятности ошибочной классификации. Для построения классификатора использовать `sklearn.neighbors.KNeighborsClassifier` библиотеки библиотеки `scikit-learn`.

4. Сравнить полученные в пп.2–3 классификаторы по качеству их работы между собой и с байесовским классификатором из л.р.№2.

5.2.3 Содержание отчета

Отчет по работе должен содержать:

1. Графическая иллюстрация данных, полученных в результате выполнения п.1 плана и результатов их классификации из пп.2–3.

2. Вероятности ошибочной классификации построенных в пп.2–3 плана классификаторов, найденные экспериментально. Результаты сравнения построенных классификаторов с байесовским классификатором.