

6 АВТОМАТИЧЕСКАЯ КЛАССИФИКАЦИЯ

Цель работы – изучение теоретических основ и экспериментальное исследование методов автоматической классификации.

В лабораторной работе изучаются методы автоматической классификации в распознавании образов. Рассматривается постановка задачи автоматической классификации, используемая при автоматической классификации меры сходства, критерии кластеризации. Рассматриваются три известных алгоритма: простой алгоритм выделения кластеров, максиминный и K внутригрупповых средних.

6.1 Теоретические основы лабораторной работы

6.1.1 Постановка задачи автоматической классификации

Пусть классификации подлежат N объектов, каждый из которых характеризуется n -мерным вектором признаков $\bar{x}$, то есть дано множество векторов $\{\bar{x}_i\}_{i=0}^{N-1}$. Эти вектора рассматриваются как фиксированные. Каждый объект должен быть отнесен к одному из L классов: $\Omega_0, \Omega_1, \dots, \Omega_{L-1}$, где число классов L может быть известно заранее или может быть не известно. Таким образом, основной вопрос задачи автоматической классификации (АК), так же как и в других задачах классификации, это вопрос об определении класса¹.

Один из возможных подходов к определению класса состоит в его понимании как *кластера (таксона)*, то есть компактной в некотором смысле области в признаковом пространстве. В этом

¹ Речь идет не о задании самого класса, а о задании областей признакового пространства, которые «соответствуют» классам.

случае задача АК является задачей *кластер-анализа* и представляет собой задачу идентификации групп схожих образов в анализируемом множестве данных (или задачу выделения кластеров).

Процесс выделения кластеров является искусством весьма «эмпирическим», так как работа конкретного алгоритма зависит не только от характера анализируемых данных, но в значительной степени и от выбранной меры подобия образов и метода, используемого для идентификации кластеров, и даже от последовательности просмотра образов.

6.1.2 Меры сходства

Для того чтобы определить на множестве данных кластеры, необходимо *в первую очередь ввести меру сходства (подобия) образов* (векторов признаков), которая может быть положена в основу правила отнесения образов характеризуемой некоторым центром кластера. В качестве мер сходства широко используются следующие:

– *евклидово расстояние* $d(\bar{x}, \bar{z}) = \|\bar{x} - \bar{z}\|$ (меньше d – больше сходство);

– *расстояние Махаланобиса* $d(\bar{x}, \bar{z}) = (\bar{x} - \bar{z})^T B^{-1} (\bar{x} - \bar{z})$ (меньше d – больше сходство). Используется, когда известны статистические характеристики кластеров (матрицы разброса);

– *косинус угла между векторами* $d(\bar{x}, \bar{z}) = \frac{\bar{x}^T \bar{z}}{\|\bar{x}\| \cdot \|\bar{z}\|}$. Данную

меру удобно использовать, когда кластеры имеют тенденцию располагаться вдоль главных осей, как, например, изображено на рисунке 6.1;

– *мера Такимото* $d(\bar{x}, \bar{z}) = \frac{\bar{x}^T \bar{z}}{\bar{x}^T \bar{x} + \bar{z}^T \bar{z} - \bar{x}^T \bar{z}}$.




Рисунок 5.1 – Иллюстрация к мерам сходства

В дальнейшем ограничимся евклидовой мерой подобия.

6.1.3 Критерии кластеризации

После выбора меры сходства необходимо определить *критерий кластеризации*. Критерий кластеризации может либо воспроизводить некие эвристические соображения, либо основываться на минимизации (или максимизации) какого-нибудь показателя качества.

При *эвристическом подходе* решающую роль играют интуиция и опыт. Он предусматривает задание набора правил, которые обеспечивают использование выбранной меры сходства для отнесения образов к одному из кластеров.

Подход к кластеризации, предусматривающий *использование показателя качества*, связан с разработкой процедур, которые обеспечат минимизацию или максимизацию выбранного показателя качества. Одним из наиболее популярных показателей является сумма квадратов ошибки:

$$\mathfrak{J} = \sum_{l=0}^{L-1} \sum_{\bar{x} \in S_l} \left\| \bar{x} - \bar{M}_l \right\|^2, \quad (4.1)$$

где L – число кластеров, S_l – множество образов (векторов признаков), относящихся к l -му кластеру, а $\bar{M}_l = \frac{1}{N_l} \sum_{\bar{x} \in S_l} \bar{x}$ – вектор вы-

борочных средних значений для множества образов S_l , величина N_l характеризует количество образов, входящих во множество S_l . Как видно, показатель качества (1) определяет общую сумму квадратов отклонений характеристик всех образов, входящих в некоторый кластер, от соответствующих средних значений по этому кластеру. Алгоритм, основанный на этом показателе качества, рассматривается ниже. Естественно, существует масса показателей качества, помимо рассмотренного. Нередко применяются алгоритмы отыскания кластеров, основанные на совместном использовании эвристического подхода и показателя качества. Примером является алгоритм ISODATA [8].

Ниже рассмотрены три наиболее известные алгоритма [8], которые являются примерами как эвристического подхода, так и подхода, использующего показатель качества.

6.1.4 Простой алгоритм выделения кластеров

Пусть задано множество N образов $\{\bar{x}_0, \bar{x}_1, \dots, \bar{x}_{N-1}\}$. Пусть также центр первого кластера $\bar{M}_0$ совпадает с любым из заданных образов и определена произвольная неотрицательная пороговая величина T ; для удобства можно считать, что $\bar{M}_0 = \bar{x}_0$. После этого вычисляется расстояние $d(\bar{M}_0, \bar{x}_1)$ между существующим центром кластера $\bar{M}_0$ и образом $\bar{x}_1$. Если это расстояние больше значения пороговой величины T ($d(\bar{M}_0, \bar{x}_1) > T$), то учреждается новый кластер с центром $\bar{M}_1 = \bar{x}_1$. В противном случае образ $\bar{x}_1$ включается в кластер, центром которого является $\bar{M}_0$. Пусть условие $d(\bar{M}_0, \bar{x}_1) > T$ выполнено, и $\bar{M}_1$ – центр нового кластера.

На следующем шаге вычисляются расстояния $d(\bar{M}_0, \bar{x}_2)$ и $d(\bar{M}_1, \bar{x}_2)$ до образа $\bar{x}_2$ от центров кластеров $\bar{M}_0$ и $\bar{M}_1$. Если

оба расстояния оказываются больше порога T ($d(\bar{M}_0, \bar{x}_2) > T$ и $d(\bar{M}_1, \bar{x}_2) > T$), то учреждается новый кластер с центром $\bar{M}_2 = \bar{x}_2$. В противном случае образ $\bar{x}_2$ зачисляется в тот кластер l ($l = 0, 1$), чей центр $\bar{M}_l$ к нему ближе.

Подобным же образом расстояния от каждого нового образа $\bar{x}_j$ ($j = 1, N-1$) до каждого известного центра кластера $\bar{M}_l$ ($l = 0, L-1$) вычисляются и сравниваются с пороговой величиной. Если все эти расстояния превосходят значение порога T ($\forall l = 0, L-1 \ d(\bar{M}_l, \bar{x}_j) > T$), то учреждается новый кластер с центром $\bar{M}_L = \bar{x}_j$ (и число кластеров увеличивается на единицу). В противном случае образ зачисляется в кластер с самым близким к нему центром.

Результаты описанной процедуры определяются выбором первого центра кластера, порядком просмотра образов, значением пороговой величины T и, конечно, геометрическими характеристиками данных.

6.1.5 Алгоритм максиминного расстояния

Алгоритм, основанный на принципе *максиминного* (максимально-минимального) *расстояния*, представляет собой еще одну простую эвристическую процедуру, использующую евклидово расстояние. Этот алгоритм в принципе аналогичен схеме из п.1.4, за исключением того обстоятельства, что в первую очередь он выявляет наиболее удаленные кластеры.

Алгоритм состоит из нескольких шагов.

Шаг 1. Произвольным образом выбирается центр первого кластера $\bar{M}_0$. Удобно выбирать в качестве центра кластера $\bar{M}_0$ тот вектор признаков $\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1}$, который обладает некоторыми

«экстремальными» свойствами. Например, удобным является тот вектор, удаление которого от среднего всех векторов из выборки максимально:

$$\bar{M}_0 = \arg \max_{\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1}} d\left(\bar{x}, \frac{1}{N} \sum_{i=0}^{N-1} \bar{x}_i\right).$$

Шаг 2. Выбирается центр второго кластера $\bar{M}_1$. В качестве центра используется тот вектор $\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1}$, который наиболее удален от первого центра кластера:

$$\bar{M}_1 = \arg \max_{\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1}} d(\bar{M}_0, \bar{x}).$$

Шаг L ($L > 2$). Выбирается центр кластера $\bar{M}_{L-1}$. Для этого вычисляются все расстояния между оставшимися образами (векторами признаков) $\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1} \setminus \{\bar{M}_l\}_{l=0}^{L-2}$ и уже существующими центрами кластеров $\bar{M}_0, \bar{M}_1, \dots, \bar{M}_{L-2}$. Для каждого оставшегося образа $\bar{x}$ находится тот центр кластера l , расстояние до которого минимально: $l = \arg \min_{l=0, L-2} d(\bar{M}_l, \bar{x})$ (вектора распределяются по кластерам по критерию близости к их центру). В качестве претендента на новый центр кластера $\bar{M}_{L-1}$ берется тот вектор признаков $\bar{x}$, у которого это минимальное расстояние (расстояние до центра «своего» кластера) максимально:

$$\bar{M}_{L-1} = \arg \max_{\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1}} \min_{l=0, L-2} d(\bar{M}_l, \bar{x}).$$

Полученное для выбранного вектора расстояние $d_{\min} = \min_{l=0, L-2} d(\bar{M}_l, \tilde{\bar{M}}_{L-1})$ от него до ближайшего кластера сравнивается с некоторым «типичным» расстоянием d_{typical} между кластерами. Если полученное расстояние больше «типичного», то этот вектор становится новым центром кластера:

$$d_{\min} > d_{\text{typical}} \Rightarrow \bar{M}_{L-1} = \tilde{\bar{M}}_{L-1}.$$

В противном случае – процесс выделения кластеров останавливается.

Выбор типичного расстояния может быть осуществлен различными способами. Один из часто используемых способов является задание типичного расстояния равного некоторой части η от среднего расстояния между уже существующими кластерами:

$$d_{\text{typical}} = \eta \left(\frac{2}{(L-1)(L-2)} \right) \sum_{l=0}^{L-2} \sum_{j=l+1}^{L-2} d(\bar{M}_l, \bar{M}_j).$$

Величина η выбирается из условия $0 < \eta < 1$. Типичное значение:

$$\eta = \frac{1}{2}.$$

6.1.6 Алгоритм K внутригрупповых средних

Алгоритмы, рассмотренные в пп. 6.1.4–6.1.5, являются, в сущности, эвристическими процедурами. Алгоритм, представленный ниже, минимизирует показатель качества, заданный как сумма квадратов расстояний всех точек, входящих в кластерную область, до центра кластера. Эта процедура, которую часто называют алгоритмом, основанным на вычислении K внутригрупповых средних, состоит из следующих шагов.

Описание алгоритма

Шаг 1. Выбираются K исходных центров кластеров на первой итерации ($r=1$): $\bar{M}_0(r), \bar{M}_1(r), \dots, \bar{M}_{K-1}(r)$. Этот выбор производится произвольно, и обычно в качестве исходных центров используются первые K образов из заданного множества $\{\bar{x}_j\}_{j=0}^{N-1}$ ($N > K$):

$$\bar{M}_0(1) = \bar{x}_0, \bar{M}_1(1) = \bar{x}_1, \dots, \bar{M}_{K-1}(1) = \bar{x}_{K-1}.$$

Номер итерации увеличивается: $r := r + 1$.

Шаг 2. На r -й итерации ($r=2, 3, \dots$) исходное множество образов $\{\bar{x}_j\}_{j=0}^{N-1}$ распределяется по K кластерам по правилу близости.

То есть некоторый образ $\bar{x} \in \{\bar{x}_j\}_{j=0}^{N-1}$ относят в кластер $S_k(r)$ ($k=0, K-1$) с центром $\bar{M}_k(r-1)$, рассчитанным на предыдущем шаге, если этот центр – ближайший:

$$\bar{x} \in S_k(r), \quad k = \arg \min_{j=0, K-1} d(\bar{x}, \bar{M}_j(r-1)).$$

Таким образом, $S_k(r)$ – множество образов, входящих в кластер с номером k на r -й итерации алгоритма. В случае равенства расстояний от некоторого образа до нескольких центров кластеров решение об отнесении этого образа к одному из них принимается произвольным образом.

Шаг 3. На основе результатов шага 2 определяются новые центры кластеров $\bar{M}_0(r), \bar{M}_1(r), \dots, \bar{M}_{K-1}(r)$ на r -й итерации алгоритма. Они определяются из условия, чтобы сумма квадратов расстояний между всеми образами, принадлежащими кла-

стеру $S_k(r)$, и новым центром кластера $\bar{M}_k(r)$ должна быть минимальной. Другими словами, новые центры кластеров выбираются таким образом, чтобы минимизировать частные показатели

$$J_k(r) = \sum_{\bar{x} \in S_k(r)} d(\bar{x}, \bar{M}_k(r))^2, \quad k=0,1,\dots,K-1$$

и, следовательно, интегральный показатель качества кластеризации на r -м шаге:

$$J(r) = \sum_{k=0}^{K-1} J_k(r) = \sum_{k=0}^{K-1} \sum_{\bar{x} \in S_k(r)} d(\bar{x}, \bar{M}_k(r))^2.$$

Для случая евклидоваго расстояния новый центр кластера $\bar{M}_k(r)$, обеспечивающий минимизацию соответствующего частного показателя $J_k(r)$, является, в сущности, выборочным средним, определенным по множеству образов в кластере $S_k(r)$:

$$\bar{M}_k(r) = \frac{1}{N_k} \sum_{x \in S_k(r)} \bar{x}, \quad k=0,1,\dots,K-1,$$

где $N_k = |S_k(r)|$ – число образов, входящих в кластер $S_k(r)$ на r -м шаге. Как видно, название алгоритма « K внутригрупповых средних» определяется способом, принятым для последовательной коррекции назначения центров кластеров.

Шаг 4. Равенство центров кластеров на соседних шагах $\bar{M}_k(r) = \bar{M}_k(r-1)$ ($k = \overline{0, K-1}$) является условием сходимости алгоритма и при его достижении выполнение алгоритма заканчивается. В противном случае алгоритм повторяется с шага 2 с новым номером итерации $r := r+1$.




Рисунок 6.1 – Пример кластеризации с использованием алгоритма K внутригрупповых средних (2 шага алгоритма)

Комментарии

Качество работы алгоритма K внутригрупповых средних зависит от числа выбираемых центров кластеров K , от выбора центров кластеров на первой итерации $\bar{M}_0(1), \bar{M}_1(1), \dots, \bar{M}_{K-1}(1)$ и, естественно, от геометрических особенностей данных. От последовательности просмотра данных результаты не зависят.

Хотя для этого алгоритма общее доказательство сходимости не известно, получения приемлемых результатов можно ожидать в тех случаях, когда данные образуют характерные гроздья, отстоящие друг от друга достаточно далеко. В большинстве случаев практическое применение этого алгоритма потребует проведения экспериментов, связанных с выбором различных значений параметра K , и расположения первоначальных центров кластеров.

6.3 Порядок выполнения лабораторной работы

6.3.1 Исходные данные

– Математические ожидания для пяти случайных векторов признаков, задаются по номеру варианта учащегося (см. раздел 7, часть 2).

6.3.2 Общий план выполнения работы

1. Смоделировать и изобразить графически обучающие выборки объема $N=50$ для пяти нормально распределенных двумерных случайных векторов с заданными математическими ожиданиями и самостоятельно подобранными корреляционными матрицами, которые обеспечивают линейную разделимость классов.
2. Объединить пять выборок в одну. Общее количество векторов в объединенной выборке должно быть 250. Полученная объединенная выборка используется для выполнения пунктов 3 и 4 настоящего плана.
3. Разработать программу кластеризации данных с использованием минимаксного алгоритма. В качестве типичного расстояния взять половину среднего расстояния между существующими кластерами. Построить отображение результатов кластеризации для числа кластеров, начиная с двух. Построить график зависимости максимального (из минимальных) и типичного расстояний от числа кластеров.
4. Разработать программу кластеризации данных с использованием алгоритма K внутригрупповых средних для числа кластеров равного 3 и 5. Для ситуации 5 кластеров подобрать начальные условия так, чтобы получить два результата: а) чтобы кластеризация максимально **соответствовала** первоначальному разбиению на классы («правильная» кластеризация); б) чтобы кластеризация максимально **не соответствовала**

ла первоначальному разбиению на классы («неправильная» кластеризация). Для всех случаев построить графики зависимости числа векторов признаков, сменивших номер кластера, от номера итерации.

6.3.3 Содержание отчета

Отчет по работе должен содержать:

- исходные данные генерируемых векторов признаков – средние и ковариационные матрицы;
- для минимаксного алгоритма: полученное число классов, график зависимости максимального и типичного расстояний от числа кластеров;
- для алгоритма K -внутригрупповых средних: график зависимости числа векторов признаков, сменивших номер кластера, от итерации алгоритма.