

1 МОДЕЛИРОВАНИЕ ЭКСПЕРИМЕНТАЛЬНЫХ ДАННЫХ ДЛЯ РЕШЕНИЯ ЗАДАЧ РАСПОЗНАВАНИЯ ОБРАЗОВ

Цель работы – подготовка экспериментального материала для решения задач распознавания образов, получение навыков работы на языке Python.

1.1 Теоретические основы лабораторной работы

1.1.1 Моделирование случайного вектора с нормальным законом распределения

Пусть $\bar{X} = (X_0, \dots, X_{n-1})^T$ – n -мерный случайный вектор, имеющий нормальный закон распределения: $\bar{X} \sim N(\bar{M}, B)$. Это означает, что плотность вероятностей случайного вектора $\bar{X}$ имеет вид

$$f(\bar{x}) = \frac{1}{(2\pi)^{n/2} \sqrt{|B|}} \exp\left(-\frac{1}{2}(\bar{x} - \bar{M})^T B^{-1}(\bar{x} - \bar{M})\right),$$

где $|\dots|$ – определитель матрицы; $(\dots)^T$ – оператор транспонирования; $\bar{M} = (M_0, \dots, M_{n-1})^T$ – вектор математических ожиданий координат вектора $\bar{X}$: $M_i = M X_i$ ($i = \overline{0, n-1}$); B – корреляционная матрица

$$B = \begin{pmatrix} B_{00} & B_{01} & \dots & B_{0(n-1)} \\ B_{10} & B_{11} & \dots & B_{1(n-1)} \\ \vdots & & & \\ B_{(n-1)0} & B_{(n-1)1} & \dots & B_{(n-1)(n-1)} \end{pmatrix},$$

элементами которой являются всевозможные корреляционные моменты: $B_{ij} = M(X_i - M_i)(X_j - M_j)$, $(i, j = \overline{0, n-1})$. Очевидно, что вектор $\bar{M}$ и матрица B полностью определяют нормальный закон распределения.

Вектор $\bar{X} \sim N(\bar{M}, B)$ можно получить специальным линейным преобразованием вектора $\bar{\xi} = (\xi_0, \dots, \xi_{n-1})^T$, компоненты которого суть независимые случайные величины, имеющие стандартный нормальный закон распределения:

$$\xi_i \sim N(0,1), \quad m_i = 0, \quad \sigma_i^2 = 1, \quad (i = \overline{0, n-1}).$$

Обычно предполагают, что матрица A преобразования $\bar{X} = A\bar{\xi} + \bar{M}$ является треугольной, то есть

$$A = \begin{pmatrix} a_{00} & 0 & \dots & 0 \\ a_{10} & a_{11} & \dots & 0 \\ \vdots & & & \\ a_{(n-1)0} & a_{(n-1)1} & \dots & a_{(n-1)(n-1)} \end{pmatrix}.$$

Коэффициенты a_{ij} легко определяются рекуррентным образом. Действительно, для диагональных элементов матрицы B справедливо соотношение

$$\begin{aligned} B_{ii} &= M[X_i - M_i]^2 = M \left[\left(\sum_{k=0}^i a_{ik} \xi_k + M_i \right) - M_i \right]^2 = \\ &= M \sum_{k=0}^i \sum_{l=0}^i a_{ik} a_{il} \xi_k \xi_l = \sum_{k=0}^i a_{ik}^2 = a_{ii}^2 + \sum_{k=0}^{i-1} a_{ik}^2, \end{aligned}$$

откуда

$$a_{ii} = \sqrt{B_{ii} - \sum_{k=0}^{i-1} a_{ik}^2}, \quad i = \overline{1, n-1}; \quad a_{00} = \sqrt{B_{00}}.$$

Для недиагональных элементов матрицы B выполняется равенство

$$B_{ij} = M(X_i - M_i)(X_j - M_j) = M\left(\sum_{k=0}^i a_{ik} \xi_k\right) \left(\sum_{l=0}^j a_{jl} \xi_l\right) = \sum_{k=0}^i \sum_{l=0}^j a_{ik} a_{jl} \underbrace{M \xi_k \xi_l}_{\delta_{kl}}.$$

Предполагая, что $i < j$, получаем

$$B_{ij} = \sum_{k=0}^i a_{ik} a_{jk} = \sum_{k=0}^{i-1} a_{ik} a_{jk} + a_{ii} a_{ji},$$

откуда

$$a_{ji} = \frac{1}{a_{ii}} \left(B_{ij} - \sum_{k=0}^{i-1} a_{ik} a_{jk} \right), \quad 1 \leq i < j \leq n-1; \quad a_{j0} = \frac{B_{0j}}{a_{00}}, \quad j = \overline{1, n-1}.$$

В частном случае, когда случайный вектор является двумерным ($n=2$), получаем следующие выражения для элементов матрицы преобразования:

$$a_{00} = \sqrt{B_{00}}, \quad a_{10} = \frac{B_{01}}{\sqrt{B_{00}}}, \quad a_{11} = \sqrt{B_{11} - \frac{B_{01}^2}{B_{00}}}.$$

Заметим, что поскольку для элементов матрицы B справедливо неравенство $|B_{ij}| \leq \sqrt{B_{ii} B_{jj}}$, ($i, j = \overline{0, n-1}$), то все коэффициенты a_{ij} корректно определены в том смысле, что подкоренные выражения в приведенных соотношениях всегда неотрицательны.

1.1.2 Оценивание параметров нормального закона распределения

Если n -мерный случайный вектор $\bar{X}$ имеет нормальный закон распределения $N(\bar{M}, B)$, то оценки максимального правдоподобия его математического ожидания $\hat{\bar{M}}$ и корреляционной матрицы $\hat{B}$, рассчитанные по выборке $\bar{x}_1, \dots, \bar{x}_N$ объема N , выглядят следующим образом:

$$\hat{\bar{M}} = \frac{1}{N} \sum_{i=1}^N \bar{x}_i, \quad \hat{B} = \frac{1}{N} \sum_{i=1}^N (\bar{x}_i - \hat{\bar{M}})(\bar{x}_i - \hat{\bar{M}})^T = \frac{1}{N} \sum_{i=1}^N \bar{x}_i \bar{x}_i^T - \hat{\bar{M}} \hat{\bar{M}}^T.$$

1.1.3 Меры близости нормальных распределений

Пусть $f_0(\bar{x})$ и $f_1(\bar{x})$ – плотности вероятностей нормально распределенного случайного вектора с параметрами:

$$f_0 \sim N(\bar{M}_0, B_0) \text{ и } f_1 \sim N(\bar{M}_1, B_1).$$

Мерой близости распределений $f_0(\bar{x})$ и $f_1(\bar{x})$ является *расстояние Бхатачария*, вычисляемое по формуле

$$\rho_B = \frac{1}{4} (\bar{M}_1 - \bar{M}_0)^T \left(\frac{B_1 + B_0}{2} \right)^{-1} (\bar{M}_1 - \bar{M}_0) + \frac{1}{2} \ln \frac{\left| \frac{B_1 + B_0}{2} \right|}{\sqrt{|B_1| \cdot |B_0|}}. \quad (1.1)$$

Для случая равных корреляционных матриц ($B_1 = B_0 = B$) в качестве меры близости распределений используют расстояние Махаланобиса между векторами средних двух нормальных распределений:

$$\rho_M(\bar{M}_0, \bar{M}_1) = (\bar{M}_1 - \bar{M}_0)^T B^{-1} (\bar{M}_1 - \bar{M}_0), \quad (1.2)$$

которое в этой ситуации с точностью до постоянного множителя совпадает с расстоянием Бхатачария. Если компоненты случайного вектора $\bar{X}$ независимы и одинаково распределены, то есть корреляционная матрица удовлетворяет условию $B=D_X I$, где I – единичная $N \times N$ матрица, а D_X – дисперсия компонент случайного вектора, то близость нормальных распределений в смысле расстояния Махаланобиса и, соответственно, Бхатачария эквивалентна близости в смысле евклидова расстояния между векторами средних:


$$\rho_E(\bar{M}_0, \bar{M}_1) = \|\bar{M}_1 - \bar{M}_0\|^2 = (\bar{M}_1 - \bar{M}_0)^T (\bar{M}_1 - \bar{M}_0).$$

Использование метрик Бхатачария или Махаланобиса в общем случае предпочтительнее евклидовой, поскольку они учитывают как дисперсии отдельных компонент случайного вектора, так и их взаимные корреляции. При этом они обладают следующим важным свойством.

Утверждение. *Расстояния Бхатачария и Махаланобиса инвариантны относительно любого невырожденного линейного преобразования случайного вектора.*


Действительно, пусть вектор $\bar{Y}$ получен в результате линейного преобразования нормально распределенного случайного вектора $\bar{X}$: $\bar{Y} = C\bar{X} + \bar{E}$, где C – матрица преобразования с отличным от нуля определителем ($|C| \neq 0$), отвечающая за поворот и масштабирование координатных осей, а $\bar{E}$ – вектор, определяющий смещения начала координат. Случайный вектор $\bar{Y}$ оказывается также распределенным нормально с параметрами:

$$\bar{M}_l^Y = C\bar{M}_l + \bar{E}, \quad B_l^Y = CB_l C^T, \quad (l=0,1). \quad (1.3)$$




$$B_0 = \begin{bmatrix} a & 0 \\ 0 & a \end{bmatrix}, B_1 = \begin{bmatrix} a & 0 \\ 0 & a \end{bmatrix};$$

$$\rho_B = 5, \rho_M = 20$$




$$B_0 = \begin{bmatrix} a & 0 \\ 0 & b \end{bmatrix}, B_1 = \begin{bmatrix} b & 0 \\ 0 & a \end{bmatrix};$$

$$\rho_B = 5, \rho_M = 18$$



$$B_0 = \begin{bmatrix} a & -b \\ -b & a \end{bmatrix}, B_1 = \begin{bmatrix} a & b \\ b & a \end{bmatrix};$$

$$\rho_B = 3.5, \rho_M = 14$$



$$B_0 = \begin{bmatrix} a & -b \\ -b & a \end{bmatrix}, B_1 = \begin{bmatrix} a & b \\ b & a \end{bmatrix}.$$

$$\rho_B = 1, \rho_M = 0$$

Рисунок 1.1 – Примеры реализаций нормально распределенных случайных векторов (f_0 – "x", f_1 – "+", $a > b > 0$)

Подставляя (1.3) в выражения для расстояний (1.1) и (1.2) и учитывая справедливость тождеств для произвольных невырожденных матриц C и B

$$|BC|=|B||C|, (BC)^T=C^T B^T, (BC)^{-1}=C^{-1}B^{-1},$$

убеждаемся в справедливости приведенного утверждения.

1.1.4 Моделирование бинарных случайных векторов с независимыми координатами

Пусть $\bar{X}=(X_0, \dots, X_{n-1})^T$ – n -мерный бинарный случайный вектор, компоненты которого принимают одно из двух значений $\{0,1\}$. Закон распределения бинарного случайного вектора задается совокупностью вероятностей $P(\bar{X}=\bar{x})$ для всех возможных значений $\bar{x}=(x_0, \dots, x_{n-1})^T$ вектора. Если координаты вектора $\bar{X}$ независимы, то распределение вероятностей записывается в виде

$$P(\bar{X}=\bar{x})=\prod_{i=0}^{n-1}P(X_i=x_i)=\prod_{i=0}^{n-1}(p_i x_i + (1-p_i)(1-x_i)),$$

где $p_i=P(X_i=1)$. Таким образом, для формирования одной реализации бинарного случайного вектора с независимыми координатами необходимо получить по одной реализации каждой из n бинарных случайных величин X_i ($i=0, n-1$).

Способ моделирования бинарной случайной величины X с распределением вероятностей $P(X=1)=p$, $P(X=0)=1-p$ основан на следующих очевидных соотношениях:

$$P\{0 \leq U < 1-p\}=1-p, \quad P\{1-p < U \leq 1\}=p,$$

где U – равномерно распределенная на отрезке $[0,1]$ случайная величина: $U \sim R[0,1]$. Таким образом случайные величины U и X связаны соотношением

$$X = [U/(1-p)],$$

где $[...]$ – целая часть числа. Следовательно, компоненты одной реализации искомого вектора могут быть получены по формуле

$$x_i = [u_i/(1-p_i)], \quad i = \overline{0, n-1},$$

здесь u_i – независимые реализации случайной величины U .

1.2 Порядок выполнения лабораторной работы

1.2.1 Исходные данные

- Вариант задания (предоставляется преподавателем).
- Математические ожидания для трех наборов двумерных нормально распределенных случайных векторов (из соответствующего варианта задания, см. раздел 7).
- Два бинарных вектора (из соответствующего варианта задания, см. раздел 7).

1.2.2 Общий план выполнения работы

1. Разработать алгоритм моделирования нормально распределенного случайного вектора с заданными математическим ожиданием и корреляционной матрицей.
2. Смоделировать и изобразить графически обучающие выборки объема $N=200$ для двух нормально распределенных двумерных случайных векторов с заданными математическими ожиданиями и самостоятельно подобранными равными корреляционными матрицами.

3. Смоделировать и изобразить графически обучающие выборки объема $N=200$ для трех нормально распределенных двумерных случайных векторов с заданными математическими ожиданиями и с неравными корреляционными матрицами, которые выбрать самостоятельно.
4. На основании полученных выборок найти точечные оценки параметров нормального закона для каждого из распределений.
5. Смоделировать обучающие выборки объема $N=200$ двух бинарных случайных векторов с распределениями, которые обеспечивают вероятность изменения указанной в представителе компоненты случайного вектора, равной $p=0.3$.

1.2.3 Содержание отчета

Отчет по работе должен содержать:

- исходные параметры моделируемых нормальных распределений; их оценки, полученные по обучающим выборкам, расстояния Бхатачария и Махаланобиса;
- графическое изображение значений векторов и имена файлов (с расширением .пру), в которые они записаны;
- распределения бинарных случайных векторов и имена записанных файлов, содержащих их реализации (с расширением .пру).