

## 4 ЛИНЕЙНЫЕ КЛАССИФИКАТОРЫ. МЕТОД ОПОРНЫХ ВЕКТОРОВ

### 4.1 Теоретические основы лабораторной работы

#### 4.1.1 Метод опорных векторов для случая линейно разделимых классов

Рассмотрим *линейный классификатор*, дискриминантная функция которого допускает представление в следующем виде:

$$d(\bar{x}) = \bar{w}^T \bar{x} + w_N \quad (4.1)$$

где  $\bar{x} = (x_0, \dots, x_{N-1})^T \in D$  – вектор признаков, который определяет образ объекта  $\omega$  в пространстве признаков  $D$ , подлежащего классификации,  $\bar{w} = (w_0, \dots, w_{N-1})^T$  – вектор весовых коэффициентов классификатора,  $w_N$  – пороговое значение. Процесс принятия решения о номере класса текущего объекта производится в соответствии со следующим правилом:

$$d(\bar{x}) = \sum_{i=0}^{N-1} w_i x_i + w_N \begin{matrix} > \\ < \end{matrix} 0 \Rightarrow \bar{x} \in \begin{matrix} D_0 \\ D_1 \end{matrix}. \quad (4.2)$$

Здесь  $D_0$  и  $D_1$  – области пространства признаков, соответствующие принятию классификатором решения, о принадлежности объекта-прообраза  $\omega$  в классе  $\Omega_0$  или  $\Omega_1$ , соответственно. Определим также *переменную правильной классификации* в виде:

$$r(\bar{x}(\omega)) = \begin{cases} 1, & \omega \in \Omega_1, \\ -1, & \omega \in \Omega_0. \end{cases}$$

Рассмотрим линейно разделимую обучающую выборку  $\{\bar{x}_i, r_j\}_{j=0}^{N-1}$  ( $r_j \equiv r(\bar{x}_j)$ ), то есть выборку, для которой найдутся параметры классификатора (1), такие что:

$$\forall j = \overline{0, N-1} \quad \bar{w}^T \bar{x}_j + w_N > 0 \wedge r_j = 1 \quad \vee \quad \bar{w}^T \bar{x}_j + w_N < 0 \wedge r_j = -1.$$

Учитывая, что «масштаб» значений дискриминантной функции не влияет на результаты классификации, можно так определить параметры классификатора, чтобы выполнялись следующие ограничения:

$$\forall j = \overline{0, N-1} \quad \left| \bar{w}^T \bar{x}_j + w_N \right| \geq 1, \quad (4.3)$$

причем равенство в указанном неравенстве происходит только для ближайших точек к разделяющей гиперплоскости (см. рисунок 4.1).

Идея *метода опорных векторов* (англ.: SVM – Support Vectors Machine) [13, 14] заключается в поиске вектора коэффициентов  $\bar{w}$  и порогового значения  $w_N$ , удовлетворяющих условию (4.3) и обеспечивающих *максимальную ширину разделяющей полосы* (см. рисунок 4.1):

$$\left| \bar{w}^T \bar{x} + w_N \right| \leq 1. \quad (4.4)$$

Можно показать, что ширина разделяющей полосы в данном случае задается величиной  $2 \|\bar{w}\|^{-1}$ . Тогда окончательный вид *задачи построения линейного классификатора по методу опорных векторов* следующий:

$$\begin{cases} \bar{w}^T \bar{w} \rightarrow \min, \\ \left( \bar{w}^T \bar{x}_j + w_N \right) \cdot r_j \geq 1, \quad j = \overline{0, N-1}. \end{cases} \quad (4.5)$$




Рисунок 4.1 – Разделяющая гиперплоскость и разделяющая полоса для линейно разделимых классов

По теореме Куна-Такера [15] эта задача квадратичного программирования с линейными ограничениями-неравенствами сводится к задаче поиска седловой точки функции Лагранжа:

$$\left\{ \begin{array}{l} \mathfrak{J}(\bar{w}, w_N, \bar{\lambda}) = \frac{1}{2} \bar{w}^T \bar{w} - \sum_{j=0}^{N-1} \lambda_j \left[ r_j \left( \bar{w}^T \bar{x}_j + w_N \right) - 1 \right] \rightarrow \min_{\bar{w}} \max_{\bar{\lambda}}, \\ \lambda_j \geq 0, \\ \left( \bar{w}^T \bar{x}_j + w_N = r_j \right) \vee \left( \lambda_j = 0 \right), \quad j = \overline{0, N-1}. \end{array} \right. \quad (4.6)$$

Здесь  $\bar{\lambda} = (\lambda_0, \dots, \lambda_{N-1})^T$  – вектор двойственных переменных. Можно показать, что данная задача эквивалентна следующей задаче квадратичного программирования относительно двойственных переменных:

$$\left\{ \begin{array}{l} -\sum_{j=0}^{N-1} \lambda_j + \frac{1}{2} \sum_{j=0}^{N-1} \sum_{i=0}^{N-1} \lambda_j \lambda_i r_j r_i \cdot \bar{x}_j^T \bar{x}_i \rightarrow \min_{\lambda}, \\ \sum_{j=0}^{N-1} \lambda_j r_j = 0; \\ \lambda_j \geq 0, \quad j = \overline{0, N-1}. \end{array} \right. \quad (4.7)$$

**Определение.** Опорным вектором выборки  $\{\bar{x}_j, r_j\}_{j=0}^{N-1}$  называется вектор  $\bar{x}_j^*$ , для которого выполняется условие:

$$\left( \bar{w}^T \bar{x}_j + w_N = r_j \right) \wedge (\lambda_j > 0). \quad (4.8)$$

Имея решение задачи (4.7) относительно вектора двойственных переменных, мы находим вектор весов классификатора по формуле:

$$\bar{w} = \sum_{j=0}^{N-1} \lambda_j r_j \cdot x_j. \quad (4.9)$$

Очевидно, что *решение есть линейная комбинация опорных векторов!* Далее имеем:

$$\bar{w}^T \bar{x} = \sum_{j=0}^{N-1} \lambda_j r_j \cdot \bar{x}_j^T \bar{x} \quad (4.10)$$

а пороговое значение может быть определено из условия:

$$\bar{w}^T \bar{x}_j^* + w_N = r_j,$$

где  $\lambda_j > 0$ , то есть по опорным векторам.

#### 4.1.2. Метод опорных векторов для случая линейно неразделимых классов

Введя дополнительные переменные  $s_j \geq 0$ , отвечающие за максимально допустимое «нарушение» объектом  $\bar{x}_j$  границы разделяющей полосы, задачу (4.5) можно переписать в следующем виде:

$$\begin{cases} \frac{1}{2} \bar{w}^T \bar{w} + C \sum_{j=0}^{N-1} s_j \rightarrow \min_{\bar{w}, \bar{s}}, \\ \left( \bar{w}^T \bar{x}_j + w_N \right) \cdot r_j \geq 1 - s_j, \\ s_j \geq 0 \quad j = 0, N-1. \end{cases} \quad (4.11)$$

Здесь величина  $C$  – параметр алгоритма, определяющий компромисс между шириной разделяющей полосы и величиной «нарушений» (ошибок), определяемой суммой  $\sum_{j=0}^{N-1} s_j$ . Проводя рассуждения, аналогичные представленным в п.4.1.1, получаем в итоге следующую задачу квадратичного программирования с двойственными переменными:

$$\begin{cases} - \sum_{j=0}^{N-1} \lambda_j + \frac{1}{2} \sum_{j=0}^{N-1} \sum_{i=0}^{N-1} \lambda_j \lambda_i r_j r_i \cdot \bar{x}_j^T \bar{x}_i \rightarrow \min_{\lambda}, \\ \sum_{j=0}^{N-1} \lambda_j r_j = 0; \\ 0 \leq \lambda_j \leq C, \quad j = 0, N-1. \end{cases} \quad (4.12)$$

Данная задача отличается от задачи (4.7) только допустимым диапазоном двойственных переменных. Определение величины  $C$  осуществляется экспериментальным путем.

### 4.1.3 Использование ядер в методе опорных векторов и переход в пространства высокой размерности

Пусть определено некоторое отображение  $\psi: D \rightarrow H$ , где  $H$  – гильбертово пространство (пространство с определенным в нем скалярным произведением). Используем для классификации образов вместо исходных описаний  $\bar{x}$  образы этих векторов признаков в новом пространстве, то есть вектора вида  $\psi(\bar{x})$ . Тогда задача (4.12) будет иметь следующий вид:

$$\left\{ \begin{array}{l} -\sum_{j=0}^{N-1} \lambda_j + \frac{1}{2} \sum_{j=0}^{N-1} \sum_{i=0}^{N-1} \lambda_j \lambda_i r_j r_i \cdot \psi(\bar{x}_j)^T \psi(\bar{x}_i) \rightarrow \min_{\bar{\lambda}}, \\ \sum_{j=0}^{N-1} \lambda_j r_j = 0; \\ 0 \leq \lambda_j \leq C, \quad j = \overline{0, N-1}. \end{array} \right. \quad (4.13)$$

Здесь  $\psi(\bar{x}_j)^T \psi(\bar{x}_i)$  – скалярное произведение в новом гильбертовом пространстве описаний, то есть симметричная и положительно определенная функция. Обозначим  $K(\bar{x}_j, \bar{x}_i) \equiv \psi(\bar{x}_j)^T \psi(\bar{x}_i)$ , такие функции называют *ядрами*. Тогда задача (4.13) может быть переписана в виде:

$$\left\{ \begin{array}{l} -\sum_{j=0}^{N-1} \lambda_j + \frac{1}{2} \sum_{j=0}^{N-1} \sum_{i=0}^{N-1} \lambda_j \lambda_i r_j r_i \cdot K(\bar{x}_j, \bar{x}_i) \rightarrow \min_{\bar{\lambda}}, \\ \sum_{j=0}^{N-1} \lambda_j r_j = 0; \\ 0 \leq \lambda_j \leq C, \quad j = \overline{0, N-1}. \end{array} \right. \quad (4.14)$$

Данная задача может быть решена так же, как и задачи (4.12)–(4.13), при этом информация о преобразовании вектора признаков  $\psi(\bar{x})$  в явном виде не требуется – достаточно знать только вид ядра  $K(\cdot, \cdot)$ .

Имея решение задачи (4.14), классификатор можно определить на основании следующих соотношений. Выражение для классификатора (4.10) преобразуется к виду:

$$\bar{w}^T \bar{x} = \sum_{j=0}^{N-1} \lambda_j r_j \cdot K(\bar{x}_j, \bar{x}) \quad (4.15)$$

и очевидным образом вычисляется с учетом известного ядра и найденного вектора двойственных переменных  $\bar{\lambda}$ . Пороговое значение рассчитывается по тем же правилам, что и в п.4.1.1, что с учетом (4.15) дает выражение:

$$w_N = r_j - \sum_{j=0}^{N-1} \lambda_j r_j \cdot K(\bar{x}_j, \bar{x}_j^*).$$

Примеры некоторых широко используемых ядер представлены в таблице 4.1 ниже. Заметим, что полиномиальное однородное ядро для  $d=2$  эквивалентно использованию отображения  $\psi(\bar{x})$ , формирующего новые признаки вида:  $\{x_i x_j\}_{0 \leq i < j < n}$  [14].

Таблица 4.1. Примеры ядер

| Наименование                | Вид ядра                                          |
|-----------------------------|---------------------------------------------------|
| Полиномиальное однородное   | $K(\bar{x}, \bar{y}) = (\bar{x}^T \bar{y})^d$     |
| Полиномиальное неоднородное | $K(\bar{x}, \bar{y}) = (\bar{x}^T \bar{y} + 1)^d$ |

| Наименование              | Вид ядра                                                                                  |
|---------------------------|-------------------------------------------------------------------------------------------|
| Радиальная функция        | $K(\bar{x}, \bar{y}) = \exp\left(-\gamma \ \bar{x} - \bar{y}\ ^2\right), \gamma > 0$      |
| Радиальная функция Гаусса | $K(\bar{x}, \bar{y}) = \exp\left(-\frac{\ \bar{x} - \bar{y}\ ^2}{2\sigma^2}\right)$       |
| Сигмоидальная функция     | $K(\bar{x}, \bar{y}) = \tanh\left(\gamma \bar{x}^T \bar{y} + c\right), \gamma > 0, c < 0$ |

#### 4.1.4 Достоинства и недостатки метода опорных векторов

##### *Достоинства метода опорных векторов*

1. Высокая «надежность» (обобщающая способность) решающего правила.
2. Универсальность, отсутствие формальных ограничений по использованию алгоритма.
3. Возможность неявного выбора пространства классификации путем явного выбора ядер.
4. Возможность неявного перехода (с использованием ядер) в пространство более высокой размерности, где классы оказываются разделимы с большей «вероятностью».

##### *Недостатки метода опорных векторов*

1. Сильное влияние шумов, так как классификатор напрямую зависит от выбранных опорных векторов.
2. Необходимость выбора параметра  $C$  для случая отсутствия линейной разделимости классов.
3. Отсутствие регулярного метода подбора ядра, связанного с выбором целевого пространства классификации.
4. Вычислительная сложность решения задач квадратичного программирования (4.7), (4.12), (4.14), которая делает затруднительным получения точного решения для больших обучающих выборок.

## 4.2 Порядок выполнения лабораторной работы

### 4.2.1 Исходные данные

- Вариант задания.
- Два файла данных, полученных в процессе выполнения первой лабораторной работы (см. раздел 1 настоящего издания) и содержащих наборы двумерных нормально распределенных векторов признаков для ситуации неравных корреляционных матриц; параметры этих законов распределения; параметры байесовского классификатора для ситуации неравных корреляционных матриц (см. раздел 2 настоящего издания).
- Исполняемый в Python файл, необходимый для выполнения пп.1 из плана выполнения лабораторной работы.

### 4.2.2 Общий план выполнения работы

1. Синтезировать линейно разделимые выборки для двух классов двумерных случайных векторов в количестве  $N=100$  штук в каждом классе с использованием предоставленного Python файла.
2. Построить линейный классификатор по методу опорных векторов на выборке с линейно разделимыми классами. Использовать для этого:
  - а) задачу (1.7) и метод решения квадратичных задач:

```
#import qpsolvers  
  
from qpsolvers import solve_qp  
  
alpha = solve_qp(P, q, G, h, A, b)
```
  - б) метод `sklearn.svm.SVC` библиотеки `scikit-learn`.
  - в) сопоставить решения из п.(б) с решением методом `LinearSVC` библиотеки `scikit-learn`.

3. Построить линейный классификатор по методу опорных векторов на выборке с линейно неразделимыми классами. Использовать для этого:
  - а) задачу (4.12) и метод решения квадратичных задач (см. выше). Указать решения для  $C=1/10, 1, 10$  и подобранно самостоятельно «лучшим коэффициентом».
  - б) метод `sklearn.svm.SVC` библиотеки `scikit-learn`.
4. Построить линейный классификатор по методу опорных векторов на выборке с линейно неразделимыми классами. Использовать для этого:
  - а) задачу (4.14) и метод решения квадратичных задач (см. выше). Исследовать решение для различных значений параметра  $C=1/10, 1, 10$  и вариантов ядер из таблицы 4.1.
  - б) метод `sklearn.svm.SVC` библиотеки `scikit-learn`.

#### ***4.2.3 Содержание отчета***

Отчет по работе должен содержать:

1. Графическая иллюстрация данных, полученных в результате выполнения п.1 плана.
2. Параметры классификаторов и опорные вектора, полученные в результате выполнения пп.2–4 плана.
3. Вероятности ошибочной классификации построенных в пп.2–4 плана классификаторов, найденные экспериментально. Результаты сравнения построенных классификаторов с байесовским классификатором.
4. Графическая иллюстрация работы итерационного процесса построения классификатора с помощью процедуры Роббинса-Монро; результаты исследования скорости сходимости этого процесса и качества классификации в зависимости от начальных условий и последовательности корректирующих коэффициентов.